

SwapAdvisor: Push Deep Learning Beyond the GPU Memory Limit via Smart Swapping

Gustavo B. P. Silva¹, Michael P. C. Silva¹, Rafael S. Melo¹

¹Departamento de Ciência da Computação – Universidade Federal de Catalão (UFCAT)

{gustavo.silva, michael.silva}@discente.ufcat.edu.br,
rafinhalelograma@hotmail.com

Resumo. Com o crescimento das Redes Neurais Profundas (DNNs), surgiram desafios significativos em relação ao uso de memória das GPUs, o que limita a capacidade de treinar e executar modelos maiores e mais precisos. A falta de memória adequada se torna um obstáculo importante no treinamento e na inferência de modelos de grande escala. Este estudo propõe o SwapAdvisor, um sistema inteligente que otimiza a troca de dados entre a memória da GPU e da CPU, visando maximizar a eficiência do uso da memória sem comprometer a precisão ou o desempenho dos modelos.

O SwapAdvisor utiliza algoritmos genéticos para determinar de forma precisa o que e quando trocar entre as memórias, aproveitando a sobreposição entre comunicação e computação para melhorar o desempenho. A avaliação do sistema demonstrou que ele pode treinar modelos até 12 vezes maiores do que o limite da memória da GPU, mantendo entre 53% e 99% da eficiência de um sistema ideal. Além disso, durante a inferência, o sistema foi capaz de reduzir a latência em até quatro vezes, mostrando eficácia mesmo em dispositivos com memória limitada, como GPUs de 128MB, e mantendo um desempenho próximo ao de sistemas com 16GB de memória.

O SwapAdvisor representa um avanço significativo no uso eficiente de memória para DNNs, permitindo o treinamento de modelos complexos em hardware comum, como GPUs de baixo custo. No entanto, a dependência de gráficos estáticos e o uso de uma única GPU indicam que há espaço para melhorias, sugerindo que mais pesquisas são necessárias para ampliar a aplicabilidade do sistema em diferentes configurações de hardware e arquiteturas.

1. Introdução

Nos últimos anos, a comunidade de aprendizado profundo tem utilizado redes neurais profundas (DNNs) maiores para melhorar a precisão em tarefas complexas (He et al. 2016, Szegedy et al. 2017, Wu et al. 2016, Zagoruyko and Komodakis 2016, Zoph et al. 2018), com um aumento constante no número de parâmetros das redes, que dobra a cada 2,4 anos desde os anos 80, impulsionado por melhorias em hardware e dados (Goodfellow et al. 2016). No entanto, a memória da GPU limita o tamanho de modelos DNN, com abordagens existentes buscando reduzir o consumo de memória através de técnicas como menor precisão em pontos flutuantes, quantização e esparsificação, mas estas podem afetar a precisão e exigem ajustes complexos de hiperparâmetros (Gupta et al. 2015, Judd et al. 2016). Outra solução é recalcular dados intermediários, mas não suporta modelos grandes (Chen et al. 2016, Martens e Sutskever 2012).

Revisar todos os acronimos do trabalho!

Se redobrar o tempo original na primeira ocorrência, depois não dá!

esse abordagem

Uma abordagem promissora é a troca de dados entre a memória da GPU e da CPU, aproveitando a maior capacidade e custo mais baixo da memória da CPU, além da melhoria na comunicação entre GPU e CPU com tecnologias como PCIe 5.0 (PCI-SIG 2019) e NVLink (Le et al. 2018, Meng et al. 2017, Rhu et al. 2016, Wang et al. 2018, NVIDIA 2018). No entanto, muitas abordagens atuais utilizam informações limitadas do gráfico de fluxo de dados para planejar a troca, prejudicando o desempenho (Yu et al. 2018, Le et al. 2018).

Neste artigo, os pesquisadores Huang, Jin e Li (2020), propuseram o SwapAdvisor, que se trata de um sistema para otimizar a troca de dados em DNNs, planejando precisamente o que e quando trocar para maximizar a sobreposição de computação e comunicação. Ele usa um algoritmo genético para otimizar a alocação de memória e o agendamento de operadores, permitindo o treinamento de modelos até 12 vezes o limite da memória da GPU, com taxas de transferência entre 53% e 99% da linha de base ideal. O SwapAdvisor também é útil para inferência, permitindo a utilização de múltiplos modelos em uma única GPU com latência reduzida em até quatro vezes em comparação com a abordagem de compartilhamento de tempo (Le et al. 2018, Meng et al. 2017).

O SwapAdvisor é o primeiro sistema geral de troca para modelos DNN grandes, mas possui limitações, como a necessidade de um gráfico de fluxo de dados estático e a limitação a uma única GPU, exigindo mais pesquisas para superar essas restrições.

A questão de pesquisa do artigo é como superar a limitação de memória da GPU para treinar e inferir modelos de redes neurais profundas (DNNs) maiores e mais precisos. A hipótese é que a troca de dados entre a memória da GPU e da CPU pode resolver essa limitação sem comprometer a precisão do modelo.

A lacuna de pesquisa identificada é a incapacidade dos métodos existentes de troca de dados de suportar modelos grandes de DNNs de forma eficiente. Os métodos atuais lidam apenas com certos modelos e não alcançam um desempenho satisfatório. O artigo propõe resolver essa limitação através de uma abordagem otimizada de troca de dados, o SwapAdvisor.

O objetivo geral deste trabalho é investigar e propor uma solução para o problema do uso eficiente da memória em Redes Neurais Profundas (DNNs), particularmente em ambientes com restrições de memória, como GPUs. Os objetivos específicos incluem:

- Revisar a literatura existente sobre técnicas de otimização de memória em DNNs.
- Identificar as limitações das abordagens atuais de troca de dados entre GPU e CPU.
- Desenvolver um sistema que otimiza a troca de dados e a sobreposição de comunicação e computação.
- Avaliar a eficácia do SwapAdvisor em diferentes cenários de uso.

2. Metodologia

A metodologia empregada neste trabalho visa a integração de múltiplas abordagens de otimização para lidar com as limitações de memória ao executar Redes

5?!
mas a o
contrário?

com
Análise
futuras?

val
de
meto-
logia.

peças.

Neurais Profundas (DNNs) em GPUs. A pesquisa explora e avalia diferentes estratégias para a troca (*swapping*) de *tensores* (estruturas de dados multidimensionais usadas para armazenar entradas, saídas e parâmetros em modelos de aprendizado de máquina) e parâmetros entre a memória da GPU e da CPU. O objetivo é permitir a execução de modelos mais profundos e maiores, sem comprometer o desempenho e a precisão.

Como objetivo geral do trabalho, pretende-se desenvolver e implementar uma solução, o SwapAdvisor, que combina técnicas de troca eficiente de *tensores* e parâmetros entre a memória da GPU e da CPU. Além disso, o SwapAdvisor incorpora técnicas de sobreposição de comunicação e computação para maximizar a eficiência do uso da GPU durante o processo de treinamento e inferência de DNNs. Essas estratégias de sobreposição visam maximizar a utilização da GPU, garantindo que a comunicação e a computação ocorram simultaneamente, reduzindo assim o tempo ocioso e melhorando o *throughput* geral do sistema. Os passos da metodologia incluem:

- Análise dos sistemas existentes: revisar e entender os sistemas de troca de memória e paralelismo de modelos existentes, como vDNN, TFLMS e SuperNeurons, para identificar suas limitações e pontos fortes. Este estudo serve como base para a criação do SwapAdvisor, buscando a superação das limitações observadas em sistemas anteriores, como a incapacidade de suportar grandes parâmetros ou modelos RNNs.
- Desenvolvimento do sistema SwapAdvisor: combinar estratégias de troca de *tensores* com sobreposição de comunicação e computação, o que permite otimizar o uso de memória da GPU sem comprometer o tempo de execução. A troca de *tensores* é feita de forma inteligente, levando em consideração os *tensores* mais críticos e as iterações anteriores. Além disso, o sistema é projetado para suportar modelos DNN de diferentes tamanhos e complexidades, como redes convolucionais (CNNs) e redes recorrentes (RNNs).
- Avaliação da abordagem SwapAdvisor: avaliar a eficácia do SwapAdvisor em termos de redução do consumo de memória e aumento do desempenho (tempo de execução). A solução foi testada em diferentes modelos DNN, desde redes mais profundas e largas até RNNs com grandes parâmetros. A avaliação comparou o SwapAdvisor com outras abordagens existentes, como recomputação, paralelismo de dados e paralelismo de modelo, para determinar suas vantagens em termos de eficiência de memória e desempenho.
- Sobreposição de comunicação e computação: implementar técnicas de sobreposição de comunicação e computação. Diferente de abordagens anteriores que dividem os kernels DNN de grão grosso em sub-kernels finos, que resultam em uma sobrecarga de desempenho, o SwapAdvisor utiliza uma abordagem de pré-busca, permitindo a sobreposição de comunicação e computação dentro de um gráfico de fluxo de dados de muitos kernels de grão grosso. Isso visa minimizar a latência e melhorar a utilização da GPU.

3. Resultados

O SwapAdvisor foi desenvolvido para superar a limitação de memória nas GPUs durante o treinamento e inferência de modelos de *deep learning*. Utilizando uma abordagem inteligente de troca de dados entre a memória da GPU e da CPU (Figura 1), o SwapAdvisor demonstrou resultados significativos mediante o uso de algoritmos

genéticos.




Figura 1. Visão geral do sistema SwapAdvisor (Baseado em Huang, Jin e Li, 2020).

Primeiramente, o SwapAdvisor conseguiu treinar modelos até 12 vezes maiores que o limite de memória da GPU, mantendo-se entre 53% a 99% (Figura 2) do *throughput* (transferência de dados) de um sistema ideal com memória infinita com base nos dados obtidos pelos pesquisadores Huang, Jin e Li (2020). Isso mostra que é possível utilizar GPUs existentes para treinar modelos maiores sem necessidade de investir em hardware mais caro ou em soluções de múltiplas GPUs, que podem ser complexas e difíceis de gerenciar. Em vez de adicionar mais GPUs (escalonamento horizontal), o SwapAdvisor otimiza o uso da memória da GPU, permitindo que modelos maiores sejam treinados em uma única GPU, reduzindo custos e simplificando a infraestrutura.




Figura 2. Latência de percentil 99 versus taxa de transferência para servir vários modelos ResNet-152 (Baseado em Huang, Jin e Li, 2020).

Além disso, o SwapAdvisor demonstrou um desempenho superior em cenários de inferência, reduzindo a latência em até 4 vezes em comparação com abordagens tradicionais de compartilhamento de tempo da memória GPU. A solução também mostrou uma melhoria na taxa de transferência de treinamento com troca de 20% a 1100% em comparação com a busca apenas de alocação de memória ou apenas de agendamento, baseados em estudos empíricos que mostram que o SwapAdvisor alcança uma taxa de *throughput* ideal muito maior do que outras abordagens. Esses resultados são especialmente notáveis em modelos mais complexos, onde a otimização conjunta de

alocação de memória e agendamento de operações pelo SwapAdvisor minimiza o tempo gasto na troca de *tensores* entre as memórias da GPU e da CPU.

Tabela 1. Estatísticas dos modelos DNN. O tamanho do lote é 64 para CNN, 256 para RNN e 128 para BRNN. (Baseado em Huang, Jin e Li (2020)).

Modelo	Utilização de memória	Operações	Tamanho de tensores
WResNet-152-10	180GB	882	26
Inception-4	71GB	830	64
NasNet-25	193GB	5533	65
RNN-8-8K	118GB	8594	7
BRNN-4-8K	99GB	9034	9

A Tabela 1 apresenta as estatísticas dos modelos DNN avaliados. Modelos como o WResNet-152-10 utilizam 180GB de memória, com 882 operações e 26 tamanhos de *tensores*. Este modelo tem uma complexidade moderada em termos de tamanhos de *tensores*. Em contraste, o Inception-4, que utiliza 71GB de memória com 830 operações, possui 64 tamanhos de *tensores*, indicando uma maior complexidade devido ao maior número de tamanhos de *tensores*. O NasNet-25, com 193GB de memória, 5533 operações e 65 tamanhos de *tensores*, é altamente complexo tanto em termos de operações quanto de tamanhos de *tensores*. Já os modelos RNN-8-8K e BRNN-4-8K, apesar de terem muitas operações (8594 e 9034, respectivamente), possuem uma baixa complexidade nos tamanhos de *tensores*, com apenas 7 e 9 tamanhos de *tensores*, respectivamente.

A eficiência do SwapAdvisor é particularmente evidente em modelos com maior complexidade de *tensores*, como o Inception-4 e o NasNet-25. A capacidade do SwapAdvisor de gerenciar a complexidade dos tamanhos de *tensores* permite otimizar tanto a alocação de memória quanto o agendamento de operações, minimizando o tempo gasto na troca de *tensores* entre as memórias da GPU e da CPU. Isso resulta em melhorias de desempenho significativas. Em modelos com menos variabilidade nos tamanhos de *tensores*, como o RNN-8-8K e o BRNN-4-8K, a eficiência do SwapAdvisor é menos impactada pela complexidade dos tamanhos de *tensores*, ~~mas~~ ainda se beneficia da otimização de agendamento devido à alta quantidade de operações.

Por fim, o SwapAdvisor foi eficaz em ambientes com memória extremamente limitada, como dispositivos com GPUs menores, funcionando com apenas 128MB de memória disponível para inferência em um modelo ResNet-152, mantendo um desempenho quase equivalente a um sistema com 16GB de memória.

Em resumo, o SwapAdvisor atingiu plenamente seus objetivos ao permitir o treinamento e inferência de modelos grandes em GPUs com memória limitada, utilizando uma abordagem de otimização automática que supera as soluções baseadas em heurísticas manuais. Ele representa um avanço significativo para a área de *deep learning*, especialmente em cenários onde a capacidade de memória é um fator crítico.

→ O trabalho apresenta a verificação, mas não mostra nenhum dado claro do sistema desenvolvido. Só fala que melhorou...

No entanto, algumas limitações permanecem, como a dependência de um gráfico de fluxo de dados estático e a restrição ao uso de uma única GPU. A escolha do Algoritmo Genético (GA), baseado em sua eficácia empírica e desempenho superior em comparação a alternativas como o recozimento simulado, também impôs certas simplificações no design, como a adoção de uma alocação baseada em conjuntos de memória, devido à dificuldade de integrar um alocador dinâmico na pesquisa do GA. Além disso, outros métodos de busca promissores, como a aprendizagem por reforço [Mirhoseini et al. 2018, Mirhoseini et al. 2017], ainda não foram explorados e poderiam superar essas limitações, oferecendo melhores resultados. Tais avanços poderiam expandir o SwapAdvisor para gráficos dinâmicos e ambientes com múltiplas GPUs, ampliando ainda mais sua eficácia e aplicabilidade.

Trabalho futuro - jogar aqui: *

3.1. Relação resultados e objetivos

Sugiro referer lendo em conta o que foi feito. de a reser de metodologia.

Os resultados alcançados pelo SwapAdvisor estão diretamente alinhados com os objetivos gerais e específicos do trabalho. O objetivo geral de investigar e propor uma solução para o uso eficiente da memória em DNNs foi plenamente atingido, com o SwapAdvisor permitindo o treinamento e a inferência de modelos significativamente maiores do que o limite de memória da GPU, sem comprometer o desempenho e a precisão.

não aparecer no trabalho.

Em relação aos objetivos específicos, o SwapAdvisor analisou sistemas existentes como vDNN, TFLMS e SuperNeurons, identificando suas limitações, como a incapacidade de suportar grandes parâmetros ou modelos RNNs. Além disso, o SwapAdvisor investigou abordagens alternativas para otimizar o uso de memória sem afetar a precisão do modelo, explorando técnicas como recomputação, paralelismo de dados e paralelismo de modelo. A solução desenvolvida combinou técnicas de troca de *tensores* e sobreposição de comunicação e computação, otimizando o uso da memória da GPU sem comprometer o tempo de execução.

onde isso aparece?

Finalmente, o SwapAdvisor foi implementado e avaliado em termos de eficiência de memória e desempenho em modelos DNN de diferentes profundidades e larguras. A avaliação detalhada mostrou a eficácia do SwapAdvisor na redução do consumo de memória e no aumento do desempenho em diversos modelos DNN, incluindo redes convolucionais (CNNs) e redes recorrentes (RNNs). Esses resultados demonstram que o SwapAdvisor não só atende aos objetivos gerais e específicos do trabalho, mas também oferece uma solução robusta e eficiente para os desafios de memória em DNNs.

não fez isso

X

4. Conclusão

vão!

o não fica demonstrado.

O SwapAdvisor demonstrou ser uma solução eficiente para superar a limitação de memória das GPUs no treinamento e inferência de modelos de redes neurais profundas (DNNs). A pesquisa revelou que o sistema proposto consegue treinar modelos até 12 vezes maiores do que o limite de memória da GPU, mantendo taxas de transferência entre 53% e 99% de um sistema ideal. Adicionalmente, no contexto de inferência, o SwapAdvisor reduziu a latência em até quatro vezes em comparação com abordagens de compartilhamento de tempo tradicionais, além de melhorar significativamente a taxa de transferência de treinamento, com ganhos entre 20% e

1100%.

Outro resultado notável foi a capacidade do SwapAdvisor de operar eficientemente em dispositivos com memória extremamente limitada, como GPUs com apenas 128MB disponíveis, atingindo um desempenho próximo ao de sistemas com 16GB. Esses avanços reforçam a aplicabilidade do SwapAdvisor tanto em cenários de alto desempenho quanto em ambientes mais restritivos, sem comprometer a precisão dos modelos.

Com base nos resultados apresentados, conclui-se que o SwapAdvisor atingiu plenamente seu objetivo de propor uma solução eficaz para o uso eficiente da memória em DNNs, resolvendo desafios enfrentados por abordagens anteriores e permitindo o treinamento e a inferência de modelos maiores e mais complexos. O artigo conseguiu expressar integralmente sua proposta e demonstrar, por meio de experimentos, a viabilidade e as vantagens do sistema desenvolvido.

Entretanto, algumas limitações permanecem, como a dependência de um gráfico de fluxo de dados estático e a restrição ao uso de uma única GPU. Essas limitações abrem espaço para estudos futuros, que poderão explorar a expansão do SwapAdvisor para gráficos dinâmicos e ambientes com múltiplas GPUs, ampliando ainda mais sua eficácia e aplicabilidade.

Em suma, o trabalho alcançou seus objetivos, oferecendo uma contribuição valiosa para a área de aprendizado profundo e estabelecendo uma base sólida para o desenvolvimento de novas soluções que continuem a otimizar o uso de memória em DNNs.

Referências

- CC. Huang, G. Jin, J. Li (2020) "SwapAdvisor: Push Deep Learning Beyond the GPU Memory Limit via Smart Swapping", In: 2020 ASPLOS '20, <https://dl.acm.org/doi/abs/10.1145/3373376.3378530>.
- Chen, T., Xu, B., Zhang, C., and Guestrin, C. (2016) "Training deep nets with sublinear memory cost", arXiv preprint arXiv:1604.06174.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016) Deep Learning, MIT Press. <http://www.deeplearningbook.org>.
- Gupta, S., Agrawal, A., Gopalakrishnan, K., and Narayanan, P. (2015) "Deep Learning with Limited Numerical Precision", In: Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37 (ICML'15), JMLR.org, pp. 1737–1746.
- He, K., Zhang, X., Ren, S., and Sun, J. (2016) "Deep Residual Learning for Image Recognition", In: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778.
- Judd, P., Albericio, J., Hetherington, T., Aamodt, T. M., Jerger, N. E., and Moshovos, A. (2016) "Proteus: Exploiting Numerical Precision Variability in Deep Neural Networks", In: Proceedings of the 2016 International Conference on Supercomputing (ICS'16), Association for Computing Machinery, Article 23.

- Le, T. D., Imai, H., Negishi, Y., and Kawachiya, K. (2018) “Tflms: Large model support in tensorflow by graph rewriting”, arXiv preprint arXiv:1807.02037.
- Martens, J., and Sutskever, I. (2012) “Training deep and recurrent networks with hessian-free optimization”, In: *Neural Networks: Tricks of the Trade*, Springer.
- Meng, C., Sun, M., Yang, J., Qiu, M., and Gu, Y. (2017) “Training deeper models by GPU memory optimization on TensorFlow”, In: *Proc. of ML Systems Workshop in NIPS*.
- Mirhoseini, A., Goldie, A., Pham, H., Steiner, B., Le, Q. V., and Dean, J. (2018) “A hierarchical model for device placement”.
- Mirhoseini, A., Pham, H., Le, Q. V., Steiner, B., Larsen, R., Zhou, Y., Kumar, N., Norouzi, M., Bengio, S., and Dean, J. (2017) “Device Placement Optimization with Reinforcement Learning”, In: *Proceedings of the 34th International Conference on Machine Learning - Volume 70 (ICML’17)*, JMLR.org, pp. 2430–2439.
- NVIDIA. (2018) “NVIDIA TensorRT”, <https://developer.nvidia.com/tensorrt>.
- PCI-SIG. (2019) “PCI Express Base Specification Revision 5.0”, <https://pcisig.com/specifications>.
- Rhu, M., Gímelshein, N., Clemons, J., Zulfiqar, A., and Keckler, S. W. (2016) “vDNN: Virtualized Deep Neural Networks for Scalable, Memory-Efficient Neural Network Design”, In: *The 49th Annual IEEE/ACM International Symposium on Microarchitecture (MICRO’49)*, IEEE Press, Article 18.
- Szegedy, C., Ioffe, S., Vanhoucke, V., and Alemi, A. A. (2017) “Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning”, In: *Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence (AAAI’17)*, AAAI Press, pp. 4278–4284.
- Wang, L., Ye, J., Zhao, Y., Wu, W., Li, A., Song, S. L., Xu, Z., and Kraska, T. (2018) “Superneurons: Dynamic GPU Memory Management for Training Deep Neural Networks”, In: *Proceedings of the 23rd ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming (PPoPP’18)*.
- Wu, Y., Schuster, M., Chen, Z., Le, Q. V., and Norouzi, M. (2016) “Google’s Neural Machine Translation System: Bridging the Gap between Human and Machine Translation”, arXiv preprint arXiv:1609.08144.
- Yu, Y., Abadi, M., Barham, P., Brevdo, E., Burrows, M., Davis, A., Dean, J., Ghemawat, S., Harley, T., Hawkins, P., and et al. (2018) “Dynamic Control Flow in Large-Scale Machine Learning”, In: *Proceedings of the Thirteenth EuroSys Conference (EuroSys’18)*, Association for Computing Machinery, Article 18.
- Zagoruyko, S., and Komodakis, N. (2016) “Wide residual networks”, arXiv preprint arXiv:1605.07146.
- Zoph, B., Vasudevan, V., Shlens, J., and Le, Q. V. (2018) “Learning Transferable Architectures for Scalable Image Recognition”, In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 8697–8710.